ハーネスに
気をつけるべき要素

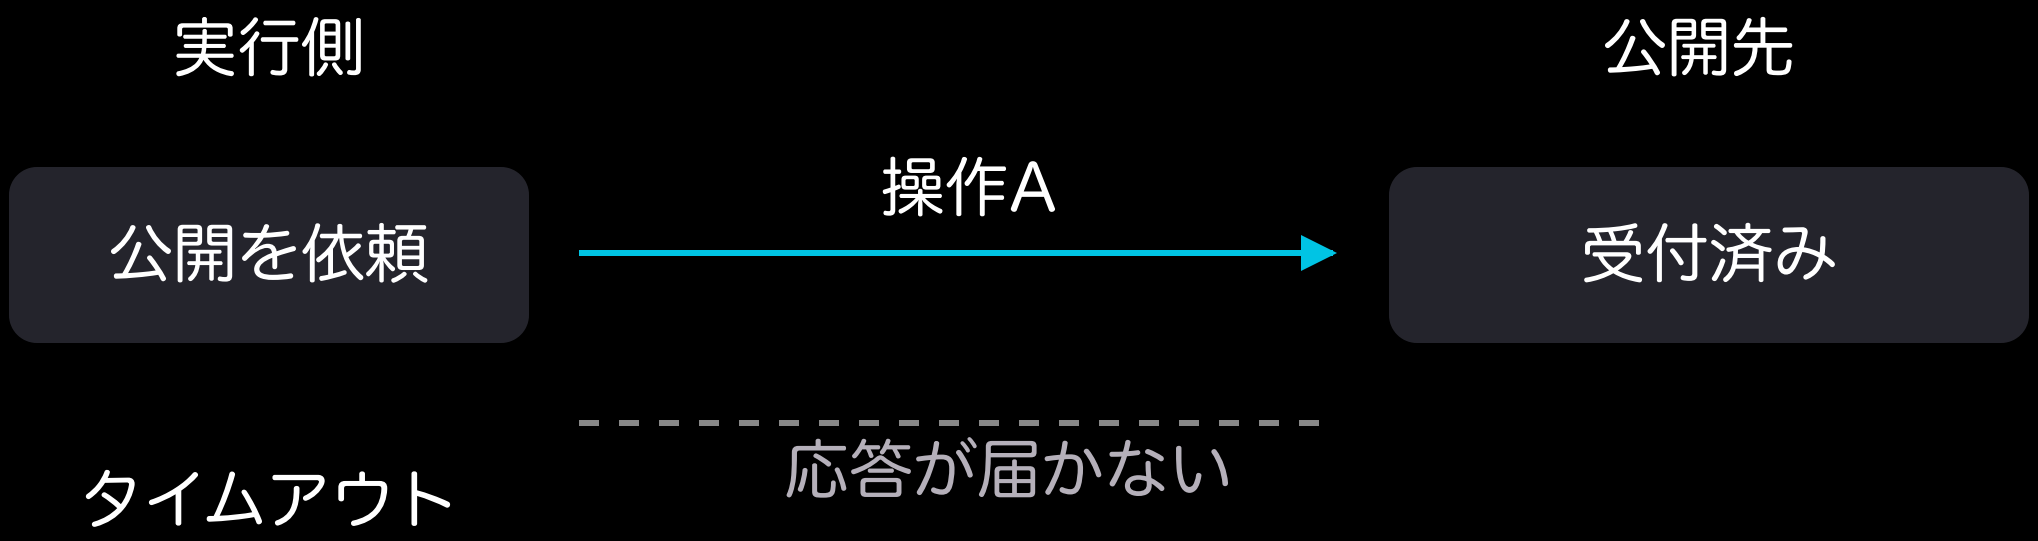
AIエージェントを動かす設計の話

AIに仕事を任せていますか？

止まった仕事を再開できますか？

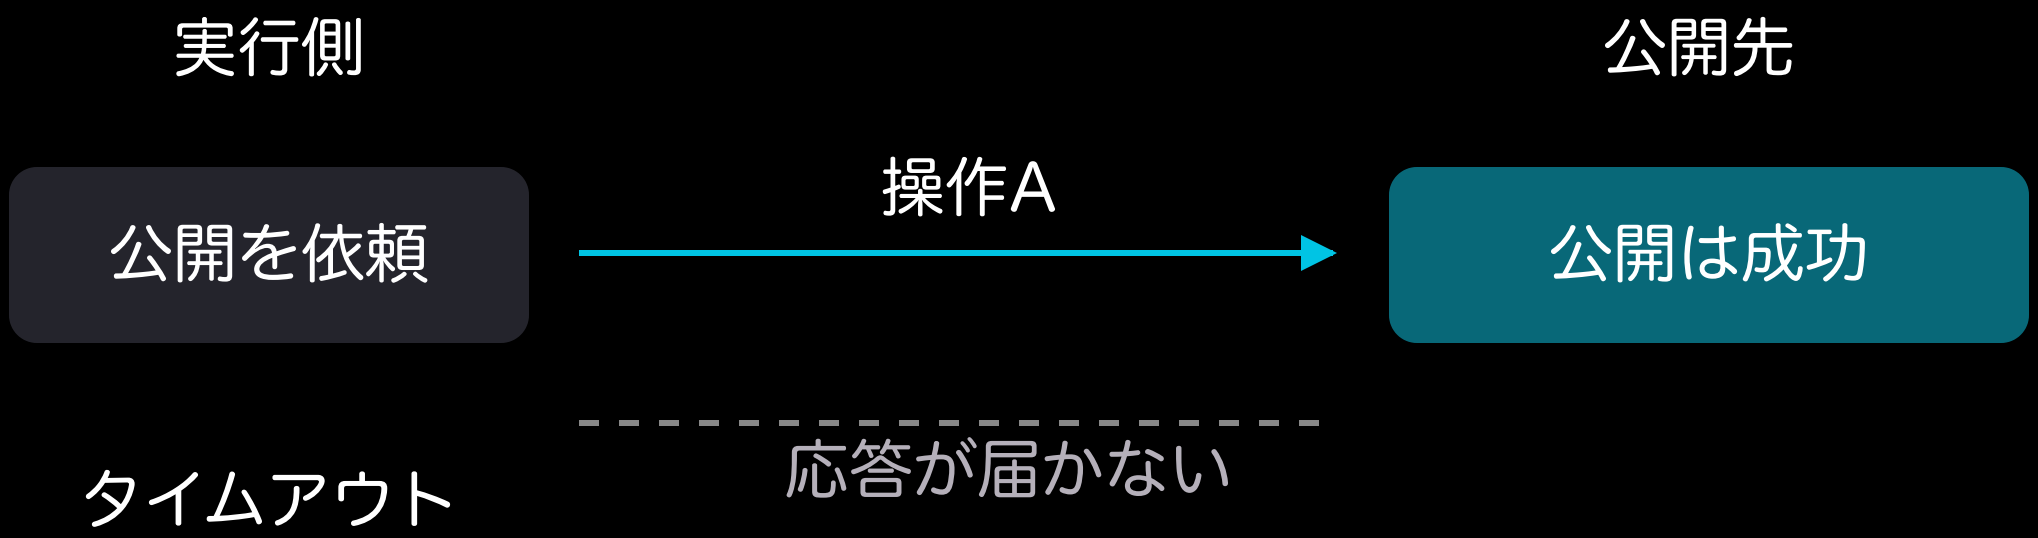
タイムアウトの向こう側

説明用の例：公開操作の応答が届かない



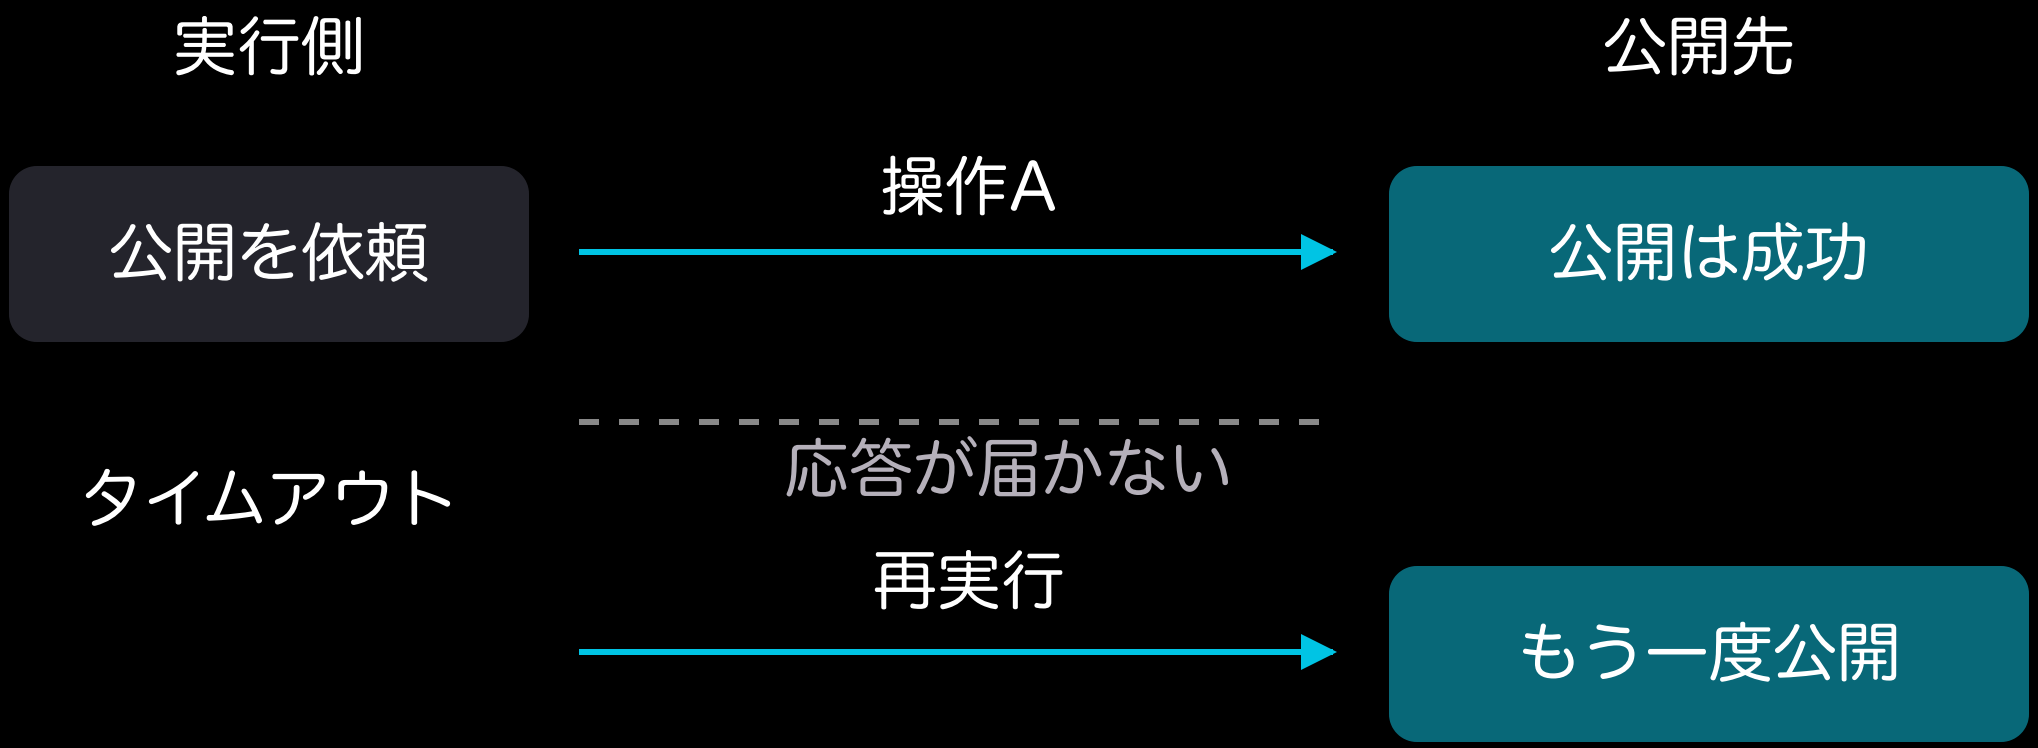
実は、公開は終わっていた

説明用の例：実行側だけが結果を知らない



同じ操作が二度走った！

説明用の例：確認せずに、もう一度実行



ハーネスは「実行の段取り」

- AIの判断を、ツールの実行につなぐ仕組み
- 使える道具と、仕事の続きを管理する
- 作業台に、鍵と作業日誌を用意するイメージ

まず、どこまで任せますか？

権限は操作の境界で分ける

操作の例	設計例
読む・直す・試す	指定の作業場で自動実行
公開・削除する	対象と既存の許可を照合
秘密情報を扱う	渡す先と読み出しを制限

外部の文章は、実行指示にしない

- WebページやIssueの本文は、調べるための材料
- そこに書かれた「別の場所へ送れ」を実行しない
- 読んだ内容で、**許可の範囲を広げない**

正本は一つに、作業場は分ける

要件・判断・進捗



編集対象は分離し、完了時に統合

「どこまで終わった？」に答える

目的	問い合わせ画面を公開する
確認済み	入力・保存のテストに合格
未確認	公開先で送信できるか
次の一手	公開先の状態を照合する

ログは保存し、文脈は選ぶ

- 元の依頼・操作・結果を、後から辿れる場所へ保存
- 今の判断に必要な要点と参照先を読み込む
- 古い指示の上書き関係と、**最新の正本**を明示

よし、続きを任せよう

再開の一手目は「照合」

実行中・成功・未実行・不明

保存した操作ID → 実行先を照合 → 次の処理へ

結果が不明なら、同じ変更を重ねない

同じ依頼には、同じ操作ID

初回	操作Aとして送る
再試行	同じ操作Aとして送る
実行先	操作Aの結果を保持する
重複依頼	実行先が二重処理を防ぐ

待つ理由で、次の一手を変える

観測した状態	次の一手
一時的な通信失敗	照合してから、間隔を空けて再試行
利用上限	回復まで待機・許可済みの代替
認証の失効	本人の再認証へ引き継ぐ

何を見て「完了」にしますか？

CIが緑。でも使えない！

説明用の例：問い合わせ画面を作った

- ビルドも、入力チェックのテストも成功
- 公開先では、送信に必要な設定が未反映
- 実際の送信操作は、まだ失敗する

完了条件は、利用者の操作で書く

- テスト用の内容を入力し、送信できる
- 保存先に、同じ内容が1件だけ届く
- 再読み込みしても、結果を確認できる

失敗を再現できる記録

- どの依頼・版・設定・モデルで動いたか
- どの道具を呼び、何が返ったか
- 何を根拠に、**完了／停止**と判断したか

止まる条件も先に決める

境界	決めておくこと
時間・利用量	1件の上限と、上限時の保存先
再試行	回数・待ち時間・打ち切り条件
人の判断	何を渡せば再開できるか

仕組みを増やすと、壊れる場所も増える

- 役割を増やすと、引き継ぎと調整も増える
- ルールを増やすと、矛盾と保守も増える
- 解きたい失敗を一つ決めて、対策を一つ足す

小さな比較で、追加の価値を測る

同じ仕事で比べる	観測するもの
完了まで進めたか	受け入れ条件の達成
人の手間は減ったか	介入・やり直しの回数
負担は増えたか	時間・利用量・保守の手間

手元の1件で、停止と再開を試そう